多模型预训练特征融合的理论说明

1 问题设定

设预训练模型池为

$$\mathcal{M} = \{m_1, \ldots, m_M\}.$$

每个模型 m 对输入 $x \in \mathcal{X}$ 输出冻结特征

$$f_m(x) \in \mathbb{R}^{d_m}.$$

对任意子集 $S \subseteq \mathcal{M}$，定义拼接特征

$$F_S(x) = \bigoplus_{m \in S} f_m(x), \qquad d_S = \sum_{m \in S} d_m.$$

目标任务标签记为随机变量 Y。在目标训练集

$$s = \{(x_i, y_i)\}_{i=1}^n \sim P^{\otimes n}$$

上，我们只训练轻量分类头或轻量融合器，而预训练编码器保持冻结。

本文主要回答两个问题：

- 为什么更多模型在总体层面不会让 Bayes 最优变差，但在有限样本下却可能使准确率先上升后下降？
- 为什么模型排序不能只看多样性，而必须同时考虑任务相关性与类条件修正项？

2 总体层面：更多模型不会让 Bayes 最优变差

命题 1 (Bayes 最优风险对特征扩充单调不增)**.** *定义子集 S 上的 Bayes 风险*

$$R^\star(S) = \inf_g \Pr[g(F_S) \neq Y],$$

其中 g 在所有可测分类器上取下确界。若 $S \subseteq T$，则

$$R^\star(T) \leq R^\star(S).$$

证明. 设 π_S 是从 F_T 到 F_S 的坐标投影。对任意定义在 F_S 上的分类器 g，都可构造定义在 F_T 上的分类器

$$\tilde{g}(F_T) = g(\pi_S(F_T)).$$

因此，T 上的分类器集合至少包含“忽略新增特征”的所有策略，于是

$$\inf_h \Pr[h(F_T) \neq Y] \leq \inf_g \Pr[g(F_S) \neq Y].$$

命题得证。 □

命题 2 (互信息对特征扩充单调不减)**.** 若 $S \subseteq T$，则

$$I(F_T; Y) = I(F_S; Y) + I(F_{T\setminus S}; Y \mid F_S) \geq I(F_S; Y).$$

证明. 直接由互信息链式法则与条件互信息非负性得到。 □

说明 1. 上面两个结论说明：在无限样本、无限算力和足够强学习器的理想条件下，增加模型不会让最优可达风险变差，也不会减少可用标签信息。因此实验中出现的”加模型掉点”不可能来自总体信息真的减少，而只能来自有限样本学习代价。

命题 3 (Excess risk 的 Rademacher 复杂度上界 [1])**.** 设 $\mathcal{H}_S$ 是在拼接特征 $F_S \in \mathbb{R}^{d_S}$ 上的线性分类器族。对线性假设类，经验 *Rademacher* 复杂度满足

$$\hat{\mathfrak{R}}_n(\mathcal{H}_S) = O\left(\sqrt{\frac{d_S}{n}}\right).$$

由 *Bartlett & Mendelson (2002)* 的经典定理，*excess risk* 以高概率有界：

$$E_n(S) = O\left(\sqrt{\frac{d_S}{n}}\right).$$

由于 $d_S = \sum_{m\in S} d_m$ 随选入模型数线性增长，因此 $c_k = E_n(S_k) - E_n(S_{k-1})$ 的量级不小于 $\Omega\big(\sqrt{d_{m_k}/n}\big)$，即新增模型的特征维度越高，有限样本代价越大。

命题 4 (冻结表示下的泛化间隙 [2])**.** *Kawaguchi et al. (ICML 2023)* 证明：在冻结表示 $Z = F_S(X)$ 上训练分类头时，泛化间隙满足

$$\textit{generalization gap} \lesssim \sqrt{\frac{I(X; Z \mid Y)}{n}} + \frac{1}{\sqrt{n}}.$$

当新增模型使拼接表示 Z 包含更多与标签 Y 无关的输入信息时，$I(X; Z \mid Y)$ 增大，从而导致泛化间隙增大。这提供了 c_k 随模型数增长的另一条理论路径：新增模型带来的不仅是维度增长，还有与任务无关的冗余信息积累。

3 有限样本层面：为什么更多模型不一定更好

定理 1 (测试风险的精确分解)**.** 设 $h_{S,n}$ 是用 n 个样本在子集 S 上学到的实际分类器，其真实风险为

$$R_n(S) \triangleq \Pr[h_{S,n}(F_S) \neq Y].$$

定义 *excess risk*

$$E_n(S) \triangleq R_n(S) - R^\star(S) \geq 0.$$

考虑一条嵌套路径

$$S_0 \subset S_1 \subset \cdots \subset S_K,$$

其中每一步只新增一个模型。则对任意 $k \geq 1$，

$$R_n(S_k) - R_n(S_{k-1}) = \underbrace{E_n(S_k) - E_n(S_{k-1})}_{\text{有限样本/优化新增代价}} - \underbrace{\big(R^\star(S_{k-1}) - R^\star(S_k)\big)}_{\textit{Bayes}\ \text{收益}}.$$

证明. 直接加减 $R^\star(S_k)$ 与 $R^\star(S_{k-1})$：

$$R_n(S_k) - R_n(S_{k-1}) = [R_n(S_k) - R^\star(S_k)] - [R_n(S_{k-1}) - R^\star(S_{k-1})] \\ - [R^\star(S_{k-1}) - R^\star(S_k)].$$

即得结论。 □

推论 1 (单步性能退化的充要条件)**.** 定义

$$\delta_k^\star \triangleq R^\star(S_{k-1}) - R^\star(S_k) \geq 0, \qquad c_k \triangleq E_n(S_k) - E_n(S_{k-1}).$$

则

$$R_n(S_k) > R_n(S_{k-1}) \quad \Longleftrightarrow \quad c_k > \delta_k^\star.$$

证明. 由上一定理直接移项即可。 □

推论 2 (更多模型不一定更好)**.** 若某一步满足

$$E_n(S_k) - E_n(S_{k-1}) > R^\star(S_{k-1}) - R^\star(S_k),$$

则加入第 k 个模型后测试风险上升，等价地，测试准确率下降。

说明 2. 这给出了“更多模型不一定更好”的严格证明。严格可证的不是“模型越多必然越差”，而是：只要新增模型带来的有限样本代价超过它带来的 Bayes 收益，测试性能就会下降。

3.1 准确率为什么会先上升后下降

命题 5 (高斯特征下互信息的次模性 [3])**.** 若各模型特征的联合分布 $(F_{m_1}, \ldots, F_{m_M}, Y)$ 服从联合高斯分布，则 $I(F_S; Y)$ 作为 S 的集合函数是单调次模的，即对任意 $S \subseteq T$ 和 $m \notin T$，

$$I(F_{T\cup\{m\}}; Y) - I(F_T; Y) \leq I(F_{S\cup\{m\}}; Y) - I(F_S; Y).$$

等价地，$\delta_k^\star = R^\star(S_{k-1}) - R^\star(S_k)$ 沿嵌套路径递减。这为”附加条件下存在最优模型数”中的条件 *1*（边际 *Bayes* 收益递减）提供了理论根据：在高斯假设下，该条件不是额外假设，而是信息论性质的直接推论。

命题 6 (附加条件下存在最优模型数)**.** 沿同一嵌套路径，若进一步满足

1. $\delta_1^\star \geq \delta_2^\star \geq \cdots$，即边际 *Bayes* 收益递减；
2. $c_1 \leq c_2 \leq \cdots$，即边际有限样本代价递增；
3. 存在某个 K 使得 $c_K > \delta_K^\star$。

则存在阈值 $K^\star$，使得对所有 $k \leq K^\star$，

$$R_n(S_k) \leq R_n(S_{k-1}),$$

而对所有 $k > K^\star$，

$$R_n(S_k) > R_n(S_{k-1}).$$

等价地，测试准确率先不上降，随后开始下降，因此存在最优模型数。

证明. 定义

$$a_k \triangleq c_k - \delta_k^\star.$$

由条件 1 和 2，a_k 单调不减。由条件 3，存在某个 K 使得 $a_K > 0$。定义

$$K^\star = \max\{k : a_k \le 0\}.$$

则对所有 $k \le K^\star$ 有 $a_k \le 0$，而对所有 $k > K^\star$ 有 $a_k > 0$。由前述精确分解

$$R_n(S_k) - R_n(S_{k-1}) = a_k,$$

即可得结论。 □

说明 3. 这里必须强调，“先升后降”不是无条件必然定理，而是在“边际收益递减、边际代价递增并最终跨越”的附加假设下成立。对于 few-shot 多模型融合，这些假设是合理的统计学习建模假设，但不是无条件真理。

3.2 为什么这些附加条件在 few-shot 下合理

在冻结编码器、仅训练轻量头部的设定中，新增模型通常同时导致：

- 输入维度 d_S 增长；
- 分类头参数量增长；
- 优化空间变大。

因此在样本量固定很小的情况下，c_k 上升是自然的。另一方面，随着已选模型数增加，新增模型提供的独立标签信息逐渐饱和，因此 $\delta_k^\star$ 递减也是自然假设。

若分类头第一层宽度固定为 512，每新增一个 768 维模型，仅第一层就新增

$$768 \times 512 = 393{,}216$$

个权重。在 few-shot 下，这个复杂度增长会直接放大 c_k。这解释了为什么实验里常见的是“前几个模型有益，后面继续加模型开始掉点”。

4 我们的方法为什么不能只看多样性

命题 7 (边际标签信息的精确分解)**.** 对候选模型 $m \notin S$，定义

$$\Delta_{\mathrm{MI}}(m \mid S) \triangleq I(F_m; Y \mid F_S).$$

则有恒等式

$$I(F_m; Y \mid F_S) = I(F_m; Y) - I(F_m; F_S) + I(F_m; F_S \mid Y).$$

证明. 对联合量 (Y, F_S) 按两种顺序展开：

$$I(F_m; Y, F_S) = I(F_m; F_S) + I(F_m; Y \mid F_S), \tag{1}$$

$$I(F_m; Y, F_S) = I(F_m; Y) + I(F_m; F_S \mid Y). \tag{2}$$

两式相等，移项即可。 □

说明 4. 这个分解给出三个组成部分：

- $I(F_m;Y)$：任务相关性；
- $I(F_m;F_S)$：冗余；
- $I(F_m;F_S \mid Y)$：类条件修正项。

因此，低冗余不是充分条件。候选模型必须既相关，又不过度冗余；如果存在类条件互补结构，第三项还会进一步修正边际收益。

5 从精确目标到可实现算法

命题 8 (贪心算法的近似保证 [4])**.** *若目标函数 $f(S)=I(F_S;Y)$ 是单调次模的（如命题 5 所保证），且贪心算法在每步选择边际增益最大的模型，则在选择 K 个模型后，贪心解 S_K^{greedy} 满足*

$$f(S_K^{\text{greedy}}) \geq \left(1-\frac{1}{e}\right) \max_{|S|\leq K} f(S).$$

即贪心选择可在多项式时间内达到最优解的 $(1-1/e)\approx 0.632$ 倍。这为本文的贪心模型选择策略提供了理论最优性保证，说明即使不做穷举搜索，贪心框架也能获得接近最优的模型子集。

5.1 原始两项排序分数

理想上，第 k 步应选择

$$m_k^\star = \arg\max_{m\notin S_{k-1}} I(F_m;Y \mid F_{S_{k-1}}).$$

但高维条件互信息很难直接稳健估计，因此原始方法只保留前两项的工程代理，构造两项排序分数

$$U_{2\text{term}}(m \mid S,T) = \widehat{R}(m,T)^\alpha \cdot \big(1-\widehat{D}(m,S)\big)^\beta.$$

其中：

- $\widehat{R}(m,T)$ 是任务相关性的代理，可取单模型精度或 LogME；
- $\widehat{D}(m,S)$ 是冗余代理，本文采用平均 CKA：

$$\widehat{D}(m,S) = \frac{1}{|S|}\sum_{j\in S} \mathrm{CKA}(F_m,F_j).$$

说明 5. 这里乘法形式的含义不是“它精确等于条件互信息”，而是强调相关性和新颖性都是必要条件。任何一项接近零，候选模型都不应有高排序分数。

5.2 第三项为什么不能直接做 set-level 估计

理论上第三项是

$$I(F_m;F_S \mid Y).$$

问题在于 F_S 是整个已选集合的拼接表示。随着 $|S|$ 增长，F_S 维度快速上升，直接估计 set-level 条件互信息

$$I(F_m;F_S \mid Y)$$

在高维、有限样本条件下非常不稳定。因此，不能声称原始两项方法已经精确处理了第三项。

5.3 第三项的更稳处理：pairwise low-order approximation

借鉴 Brown 等人关于信息论特征选择的统一分析，可以用 pairwise 低阶近似替代 whole-set 的第三项，即用

$$\widehat{C}(m,S)=\frac{1}{|S|}\sum_{j\in S}\widehat{I}(F_m;F_j\mid Y)$$

近似类条件修正作用。于是得到三项评分

$$\mathrm{Score}_{3\mathrm{term}}(m\mid S)=\widehat{R}(m)-\lambda\widehat{D}(m,S)+\eta\widehat{C}(m,S).$$

本文在实现上进一步采用如下可计算近似：

1. 先对每个模型特征做 PCA 降维；
2. 对每个类别 y 假设类条件特征近似服从高斯分布；
3. 估计

$$I(F_m;F_j\mid Y)=\sum_y p(y)I(F_m;F_j\mid Y=y).$$

说明 6. 因此，第三项当前的严谨说法应当是：我们没有直接估 set-level 的 $I(F_m;F_S\mid Y)$，而是使用 Brown 风格的 pairwise low-order approximation，并用 “PCA + 类条件高斯” 估计器对其进行近似实现。它不是无偏估计，也不是严格一致估计，而是一个有文献依据的可计算近似。

5.4 class-conditional CKA 的角色

如果进一步计算

$$\widehat{D}_{\mathrm{cc}}(m,S)=\sum_y\hat{p}(y)\frac{1}{|S|}\sum_{j\in S}\mathrm{CKA}(F_m^{(y)},F_j^{(y)}),$$

那么这个量只能被看作标签条件相似性的诊断统计量，而不能被当作

$$I(F_m;F_S\mid Y)$$

或

$$\frac{1}{|S|}\sum_{j\in S}I(F_m;F_j\mid Y)$$

的互信息估计器。因此，ccCKA 只能用于补充分析，不能直接替代第三项本身。

6 为什么用 CKA 作为冗余代理是合理的

6.1 CKA 与 HSIC 的形式化关系

CKA 本质上是 Hilbert-Schmidt Independence Criterion (HSIC) 的归一化形式。对居中后的 Gram 矩阵 K 和 L（分别对应表示 F_i 和 F_j 的线性核），CKA 定义为

$$\mathrm{CKA}(F_i,F_j)=\frac{\mathrm{HSIC}(F_i,F_j)}{\sqrt{\mathrm{HSIC}(F_i,F_i)\cdot\mathrm{HSIC}(F_j,F_j)}},$$

其中经验 HSIC 为

$$\widehat{\mathrm{HSIC}}(F_i,F_j)=\frac{1}{(n-1)^2}\mathrm{tr}(KHLH),$$

$H=I_n-\frac{1}{n}\mathbf{1}\mathbf{1}^\top$ 为居中矩阵。

命题 9 (HSIC 的独立性判据 [6])**.** *Gretton et al. (JMLR 2005)* 证明：当使用特征核（如高斯核或线性核在充分丰富的特征空间中）时，$\mathrm{HSIC}(F_i, F_j) = 0$ 当且仅当 $F_i \perp\!\!\!\perp F_j$。因此 $\mathrm{CKA} = 0$ 意味着两组表示完全独立（无冗余），$\mathrm{CKA} \to 1$ 意味着表示高度线性相关（高冗余）。这为使用 *CKA* 作为 $I(F_m; F_S)$ 的单调代理提供了统计独立性层面的理论基础。

6.2 高维退化与 CKA 的稳健性

Kornblith 等人在 ICML 2019 证明：当表示维度大于样本数时，任何对可逆线性变换都不变的相似度统计量都会退化。其核心结论可写为如下命题。

命题 10 (改写自 Kornblith et al. 的高维退化结论)**.** 令 $X, Y \in \boldsymbol{R}^{n\times p}$ 且 $\mathrm{rank}(X) = \mathrm{rank}(Y) = n$。若相似度统计量 $s(\cdot,\cdot)$ 对第一自变量满足可逆线性变换不变性，即

$$s(X, Z) = s(XA, Z)$$

对任意可逆 $A \in \boldsymbol{R}^{p\times p}$ 都成立，则对任意 Z 都有

$$s(X, Z) = s(Y, Z).$$

证明. 证明思路与 Kornblith 等人的补充材料一致：通过为 X 与 Y 分别补足零空间基，构造两个可逆矩阵 X' 与 Y'，再令 $A = (X')^{-1}Y'$，即可得到 $XA = Y$，随后由可逆线性变换不变性推出结论。 □

说明 7. 这个结果说明，过强的不变性会使高维表示相似度退化。CKA 仅保持对正交变换和各向同性缩放的不变性，因此比 CCA 一类完全可逆不变的统计量更适合作为高维特征冗余的代理。不过仍需明确：CKA 只是冗余代理，不是互信息估计器。

7 实验协议与代码实现对应

数据协议 当前代码实现采用严格的 train/val/test 三段协议。模型排序所需的统计量只在目标任务的训练部分上估计；验证集只用于选择模型子集、选择超参数以及决定最终 checkpoint；测试集只在所有选择步骤完成后用于一次性最终报告。因此，测试集标签不会再进入模型排序或 checkpoint 选择流程。

方法主线 实现上区分两条分支：

- 两项分支是主方法：使用 $\widehat{R}$ 与 $\widehat{D}$ 构造排序分数，作为默认排序策略；
- 三项分支是扩展方法：在两项主线之外，额外加入 pairwise low-order conditional term，用于补充验证第三项是否能带来额外收益。

当前主实验比较的方法 当前正式多数据集实验比较的是九种模型选择策略，它们先在训练集特征上给出排序，再在统一融合器下搜索最优模型数。具体包括：

- **Ours (LogME+CKA)**：以 LogME 作为任务相关性代理，以 CKA 作为冗余代理，按 relevance-redundancy 贪心准则排序；
- **GBC+CKA** 与 **H-Score+CKA**：保留相同的冗余项，只将相关性代理分别替换为 GBC 与 H-Score；

- **LogME+SVCCA**：保留 LogME 相关性项，但将冗余代理替换为 SVCCA，用于比较不同表示相似度统计量的影响；
- **mRMR 与 JMI**：作为经典信息论特征选择基线，对应传统 relevance-redundancy 家族的代表方法；
- **Relevance Only**：只按单模型相关性排序，不显式惩罚模型间冗余；
- **Random**：随机给出模型顺序，用作弱基线；
- **All Models**：不做精细排序，而是把全部候选模型依次纳入，用作“只堆模型不做选择”的对照组。

因此，当前经验部分真正回答的问题不是“某一个融合器是否最优”，而是：在固定融合训练协议下，哪一种模型选择策略更能稳定找到高质量的模型子集。

第三项的代码化版本与消融定位 除主表中的九种方法外，代码中还额外实现了一个不并入主表的三项消融版本，用于专门回答“第三项是否重要”。它仍然以 LogME 作为相关性代理、以 CKA 作为冗余代理，但在第二项之外显式加入类条件修正项的低阶近似。记

$$C_{\text{pair}}(m, S_{t-1}) = \frac{1}{|S_{t-1}|} \sum_{j \in S_{t-1}} \widehat{I}(F_m; F_j \mid Y),$$

其中 $\widehat{I}(F_m; F_j \mid Y)$ 是在类条件高斯假设与 PCA 降维下得到的 pairwise conditional MI 估计。则第三项消融版本的打分写为

$$\text{Score}_{\text{3term}}(m \mid S_{t-1}) = \bar{R}_{\text{LogME}}(m) - \lambda \bar{D}_{\text{CKA}}(m, S_{t-1}) + \eta C_{\text{pair}}(m, S_{t-1}).$$

本文将它作为 *ablation variant*，而不是主实验默认方法：主实验先比较两项主线是否已经足够稳定；若需要进一步验证第三项是否带来额外收益，再单独运行这一三项版本并与两项版本做一对一对比。

九种方法的统一数学形式 设候选模型池为 $\mathcal{M}$，第 t 步已选集合为 S_{t-1}，剩余候选集合为

$$U_{t-1} = \mathcal{M} \setminus S_{t-1}.$$

记模型 m 在当前目标任务训练集上的冻结特征矩阵为

$$F_m \in \mathbb{R}^{n \times d_m},$$

标签向量为 $y \in \{1, \ldots, C\}^n$。对 relevance-redundancy 家族的方法，代码先计算每个模型的相关性分数 $R(m)$，再做 min-max 归一化：

$$\bar{R}(m) = \frac{R(m) - \min_{j \in \mathcal{M}} R(j)}{\max_{j \in \mathcal{M}} R(j) - \min_{j \in \mathcal{M}} R(j)}.$$

若分母为零，则所有模型的归一化相关性都置为 0。对任意冗余统计量 $\rho(\cdot, \cdot)$，定义候选模型相对已选集合的平均冗余为

$$\bar{D}_\rho(m, S_{t-1}) = \frac{1}{|S_{t-1}|} \sum_{j \in S_{t-1}} \rho(F_m, F_j), \qquad |S_{t-1}| \geq 1.$$

于是统一的贪心打分写成

$$\mathrm{Score}_{q,\rho}(m \mid S_{t-1}) = \bar{R}_q(m) - \lambda \bar{D}_\rho(m, S_{t-1}),$$

其中 q 表示相关性代理，ρ 表示冗余代理，实验中固定 $\lambda = 1$。第一步没有冗余项，因此

$$m_1 = \arg\max_{m \in \mathcal{M}} \bar{R}_q(m),$$

后续各步选择

$$m_t = \arg\max_{m \in U_{t-1}} \mathrm{Score}_{q,\rho}(m \mid S_{t-1}).$$

相关性代理的数学定义 当前实验实际用到三种相关性代理。

1. LogME. 对每个模型 m，令 $F_m = U\Sigma V^\top$ 为其特征矩阵的奇异值分解，并把多分类问题拆成 one-vs-rest 回归目标 $y^{(c)} \in \{0,1\}^n$。LogME 取每个类别的 Bayesian linear evidence 的平均：

$$R_{\mathrm{LogME}}(m) = \frac{1}{C} \sum_{c=1}^{C} \mathcal{E}(F_m, y^{(c)}),$$

其中

$$\mathcal{E}(F, y) = \frac{1}{2}\Big(d \log \alpha + n \log \beta - \beta \|y - Fw\|_2^2 - \alpha \|w\|_2^2 - \log\det(\alpha I + \beta F^\top F) - n \log(2\pi)\Big),$$

参数 α, β 由 evidence maximization 的固定点迭代求得。直观上，$R_{\mathrm{LogME}}(m)$ 越大，表示该冻结表示越容易被一个轻量线性头解释当前标签。

2. GBC. 对每个类别 c，在表示空间中拟合高斯分布

$$F_m \mid Y = c \sim \mathcal{N}(\mu_c, \Sigma_c).$$

对任意类别对 (c, c')，Bhattacharyya 距离定义为

$$D_B(c, c') = \frac{1}{8}(\mu_c - \mu_{c'})^\top \Sigma^{-1} (\mu_c - \mu_{c'}) + \frac{1}{2} \log \frac{\det \Sigma}{\sqrt{\det \Sigma_c \det \Sigma_{c'}}}, \qquad \Sigma = \frac{\Sigma_c + \Sigma_{c'}}{2}.$$

GBC 相关性分数是所有类别对距离的平均：

$$R_{\mathrm{GBC}}(m) = \frac{1}{|\{(c, c') : c < c'\}|} \sum_{c < c'} D_B(c, c').$$

该分数越大，表示不同类别在当前表示空间中的类间可分性越强。

3. H-Score. 记总体协方差为 $\mathrm{Cov}(F_m)$，类条件均值的协方差为

$$\mathrm{Cov}\big(\mathbb{E}[F_m \mid Y]\big).$$

H-Score 定义为

$$R_{\mathrm{HScore}}(m) = \mathrm{tr}\Big(\mathrm{Cov}(F_m)^{-1} \mathrm{Cov}\big(\mathbb{E}[F_m \mid Y]\big)\Big).$$

它衡量的是“类间结构”相对于“总体变化”的强度，数值越大通常表示该表示对下游分类越友好。

冗余代理的数学定义 当前实验实际用到两种冗余统计量。

1. CKA. 对两个模型表示 F_i, F_j，线性 CKA 写为

$$\rho_{\mathrm{CKA}}(F_i, F_j) = \mathrm{CKA}(F_i, F_j) = \frac{\|F_j^\top F_i\|_F^2}{\sqrt{\|F_i^\top F_i\|_F^2 \cdot \|F_j^\top F_j\|_F^2}},$$

在高维大样本不平衡时，代码也允许切换到等价的 kernel-space 形式。CKA 越大，表示两组特征越相似、冗余越强。

2. SVCCA. 对每个模型表示先做 PCA，保留累计解释方差达到阈值 $\tau = 0.99$ 的主成分，且最多保留 128 维，得到降维表示 $\widetilde{F}_i, \widetilde{F}_j$。然后计算 canonical correlations

$$\sigma_1, \ldots, \sigma_K, \qquad K = \min\{\dim(\widetilde{F}_i), \dim(\widetilde{F}_j), n\}.$$

SVCCA 相似度定义为这些 canonical correlations 的平均：

$$\rho_{\mathrm{SVCCA}}(F_i, F_j) = \frac{1}{K} \sum_{\ell=1}^{K} \sigma_\ell.$$

与 CKA 一样，数值越大表示两种表示越接近。

九种选择方法逐一写开 1. Ours (LogME+CKA). 这是本文主方法，取

$$q = \mathrm{LogME}, \qquad \rho = \mathrm{CKA},$$

因此每一步选择

$$m_t^{\mathrm{ours}} = \arg\max_{m \in U_{t-1}} \Big[\bar{R}_{\mathrm{LogME}}(m) - \bar{D}_{\mathrm{CKA}}(m, S_{t-1}) \Big].$$

2. GBC+CKA. 与主方法完全共用同一贪心框架，只把相关性代理替换为 GBC：

$$m_t^{\mathrm{GBC+CKA}} = \arg\max_{m \in U_{t-1}} \Big[\bar{R}_{\mathrm{GBC}}(m) - \bar{D}_{\mathrm{CKA}}(m, S_{t-1}) \Big].$$

3. H-Score+CKA. 同理，把相关性代理替换为 H-Score：

$$m_t^{\mathrm{HScore+CKA}} = \arg\max_{m \in U_{t-1}} \Big[\bar{R}_{\mathrm{HScore}}(m) - \bar{D}_{\mathrm{CKA}}(m, S_{t-1}) \Big].$$

4. LogME+SVCCA. 保留 LogME 相关性，但把冗余统计量从 CKA 替换为 SVCCA：

$$m_t^{\mathrm{LogME+SVCCA}} = \arg\max_{m \in U_{t-1}} \Big[\bar{R}_{\mathrm{LogME}}(m) - \bar{D}_{\mathrm{SVCCA}}(m, S_{t-1}) \Big].$$

这个方法用于检验“冗余代理的具体选择”是否会改变排序质量。

5. mRMR. 这一路径不走上面的统一贪心打分，而是调用经典 mRMR 准则。代码先把每个模型特征经 PCA 压到最多 64 维，再用高斯近似估计互信息。其目标是

$$J_{\mathrm{mRMR}}(m \mid S_{t-1}) = I(F_m; Y) - \frac{1}{|S_{t-1}|} \sum_{j \in S_{t-1}} I(F_m; F_j).$$

第一步选

$$m_1^{\mathrm{mRMR}} = \arg\max_{m \in \mathcal{M}} I(F_m; Y),$$

之后选

$$m_t^{\mathrm{mRMR}} = \arg\max_{m \in U_{t-1}} J_{\mathrm{mRMR}}(m \mid S_{t-1}).$$

其中 $I(F_m; Y)$ 和 $I(F_m; F_j)$ 都是用高斯协方差与对数行列式构造的可计算估计量。

6. JMI. JMI 同样先做 PCA 降维，再使用高斯近似。第一步仍按

$$m_1^{\mathrm{JMI}} = \arg\max_{m \in \mathcal{M}} I(F_m; Y)$$

选择，后续各步最大化

$$J_{\mathrm{JMI}}(m \mid S_{t-1}) = \sum_{j \in S_{t-1}} I(F_m, F_j; Y).$$

因此

$$m_t^{\mathrm{JMI}} = \arg\max_{m \in U_{t-1}} \sum_{j \in S_{t-1}} I(F_m, F_j; Y).$$

直观上，JMI 鼓励新模型与已选模型一起对标签提供大的联合信息。

7. Relevance Only. 这是只看单模型相关性的弱化版本，不显式惩罚冗余：

$$m_t^{\mathrm{RelOnly}} = \arg\max_{m \in U_{t-1}} R_{\mathrm{LogME}}(m).$$

等价地，它只是把所有模型按 LogME 从高到低排序。

8. Random. 随机基线不使用任何统计量。给定随机种子后，对候选模型集合做一次随机置换

$$\pi : \mathcal{M} \to \mathcal{M},$$

然后取前 K 个模型：

$$(m_1^{\mathrm{rand}}, \ldots, m_K^{\mathrm{rand}}) = (\pi(1), \ldots, \pi(K)).$$

因此它只回答“一个无信息顺序能做到什么程度”。

9. All Models. 这个对照组也不计算任何分数，而是把候选池中全部模型按照固定的确定性枚举顺序直接纳入。若记这个固定顺序为

$$(a_1, \ldots, a_{|\mathcal{M}|}),$$

则第 k 步对应的模型子集就是

$$S_k^{\mathrm{all}} = \{a_1, \ldots, a_k\}.$$

它的意义不是提供一个“聪明排序”，而是回答：如果完全不做选择、只是不断往里加模型，性能会怎样变化。

8 多数据集经验结果汇总

只报告单个数据集（例如仅报告 DTD）不足以支撑选择方法层面的总体结论。按照当前代码与实验脚本的协议，更合适的主实验应至少覆盖 STL10、Pets、EuroSAT、DTD、GTSRB 与 SVHN 六个数据集，并在固定融合器下比较不同选择方法得到的最优结果。

主实验流水线严格分为三个阶段：第一阶段对每个数据集、每个候选预训练模型提取冻结特征；第二阶段仅在训练集特征上运行上述九种选择策略并得到排序；第三阶段固定使用同一融合训练协议，对每种排序从小到大搜索模型数 k，在验证集上选择最优 k，最后只在测试集上做一次最终报告。当前脚本的默认设置是在 14 个候选模型中取前 $k \leq 10$ 个进入融合训练，因此结果表反映的是“固定候选池、固定融合器、比较不同选择方法”的主实验，而不是单一数据集上的局部缩放示例。

本节只保留当前已经完成的结果展示。截至 2026 年 3 月 23 日 00:20（China Standard Time），已有完整方法比较结果的数据集为 STL10、Pets、EuroSAT、DTD。其余数据集里，GTSRB 已完成 6/9 个方法；SVHN 尚未进入汇总表。

Method	STL10	Pets	EuroSAT	DTD	Avg.
Ours (LogME+CKA)	99.28	96.40	98.02	82.02	93.93
GBC+CKA	**99.31**	96.43	98.09	81.65	93.87
H-Score+CKA	99.28	96.38	98.09	82.23	93.99
LogME+SVCCA	99.28	**96.59**	98.15	81.97	94.00
mRMR	99.21	96.27	98.13	81.65	93.81
JMI	99.28	96.54	**98.17**	82.13	94.03
Relevance Only	99.28	**96.59**	98.06	**82.29**	94.05
Random	99.26	96.29	98.00	81.86	93.85
All Models	**99.31**	96.27	97.81	81.97	93.84

表 1: Current complete-dataset snapshot of selection methods as of March 23, 2026. Only datasets with all nine methods finished are shown. Each cell reports the best test accuracy (%) over the completed range $k = 2, \ldots, 10$.

8.1 当前完整快照

表 1 给出了截至 2026 年 3 月 23 日当前已完成数据集上的完整结果快照。为了保证比较公平，表中只保留了九种方法都已经完成的四个数据集：STL10、Pets、EuroSAT 和 DTD。每个单元格都报告该方法在对应数据集上、当前已完成的 $k = 2, \ldots, 10$ 搜索范围内所达到的最佳测试准确率。

图 1 用更直接的柱状图汇总四个已完成数据集上的三类结果：当前两项方法、该数据集上当前最强的 baseline，以及完全不做选择的 All Models。对于当前这版阶段性分析，柱状图比折线图更合适，因为我们这里要强调的是“横向方法比较”，而不是完整的 scaling trajectory。

9 哪些地方是严格证明，哪些地方只是带条件或近似

严格可证的部分

- Bayes 风险对特征扩充单调不增；
- 互信息对特征扩充单调不减；
- 测试风险的精确分解；
- 单步性能退化的充要条件；
- 边际标签信息的三项精确分解。

带条件成立的部分

- “准确率先上升后下降”需要附加假设：边际收益递减、边际代价递增并最终跨越；
- “存在最优模型数”不是无条件普适定理，而是针对 few-shot 融合的合理结构假设下成立。

工程近似与实验协议的部分

- $\widehat{R}$ 不是互信息本身，只是相关性的代理；
- CKA 不是 $I(F_m; F_S)$ 的无偏估计，只是冗余代理；
- 第三项采用 pairwise low-order approximation，而不是 set-level 条件互信息的直接估计；

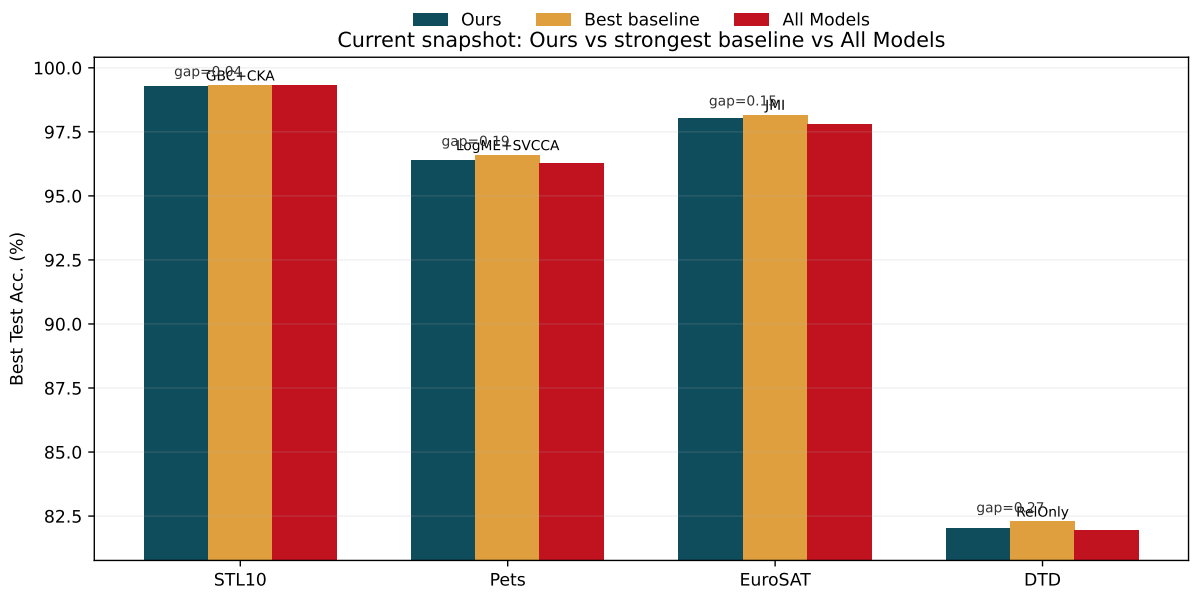

图 1: Current snapshot on the completed datasets. For each dataset, we compare the current two-term method, the strongest finished baseline, and the no-selection All Models result using their best finished test accuracy.

- PCA + 类条件高斯估计器是可计算近似，不是严格一致估计；
- class-conditional CKA 只是探索性诊断，不能替代第三项。
- 经验评估采用 train/val/test 协议，其中 test 只用于最终一次报告。

参考文献

[1] P. L. Bartlett and S. Mendelson. Rademacher and Gaussian complexities: Risk bounds and structural results. *Journal of Machine Learning Research*, 3:463–482, 2002.

[2] K. Kawaguchi, Z. Deng, X. Ji, and J. Huang. How does information transfer in deep neural networks? In *Proceedings of the 40th International Conference on Machine Learning (ICML)*, 2023.

[3] A. Krause, A. Singh, and C. Guestrin. Near-optimal sensor placements in Gaussian processes: Theory, efficient algorithms and empirical studies. *Journal of Machine Learning Research*, 9:235–284, 2008.

[4] G. L. Nemhauser, L. A. Wolsey, and M. L. Fisher. An analysis of approximations for maximizing submodular set functions—I. *Mathematical Programming*, 14(1):265–294, 1978.

[5] G. F. Hughes. On the mean accuracy of statistical pattern recognizers. *IEEE Transactions on Information Theory*, 14(1):55–63, 1968.

[6] A. Gretton, O. Bousquet, A. Smola, and B. Schölkopf. Measuring statistical dependence with Hilbert-Schmidt norms. In *Proceedings of the 16th International Conference on Algorithmic Learning Theory (ALT)*, pages 63–77, 2005.

[7] S. Kornblith, M. Norouzi, H. Lee, and G. Hinton. Similarity of neural network representations revisited. In *Proceedings of the 36th International Conference on Machine Learning (ICML)*, pages 3519–3529, 2019.

[8] G. Brown, A. Pocock, M.-J. Zhao, and M. Luján. Conditional likelihood maximisation: A unifying framework for information theoretic feature selection. *Journal of Machine Learning Research*, 13:27–66, 2012.

[9] N. Tishby, F. C. Pereira, and W. Bialek. The information bottleneck method. *arXiv preprint physics/0004057*, 2000.

[10] K. You, Y. Liu, J. Wang, and M. Long. LogME: Practical assessment of pre-trained models for transfer learning. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, pages 12133–12143, 2021.

[11] C. Nguyen, T. Hassner, M. Seez, and C. Archambeau. LEEP: A new measure to evaluate transferability of learned representations. In *Proceedings of the 37th International Conference on Machine Learning (ICML)*, pages 7294–7305, 2020.

[12] S. Pandy, A. Agostinelli, and J. Uijlings. Transferability estimation using Bhattacharyya class separability. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 9172–9182, 2022.

[13] Y. Bao, Y. Li, S.-L. Huang, L. Zhang, L. Zheng, A. Zamir, and L. Guibas. An information-theoretic approach to transferability in task transfer learning. In *Proceedings of the 26th International Conference on Machine Learning (ICML)*, pages 2309–2318, 2019.

[14] M. Raghu, J. Gilmer, J. Yosinski, and J. Sohl-Dickstein. SVCCA: Singular vector canonical correlation analysis for deep learning dynamics and interpretability. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 6076–6085, 2017.